

Trabajo Práctico 3: OCR+SVD

Métodos Numéricos

Laboratorio

Departamento de Computación
Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

1er cuatrimestre 2013

Trabajo Práctico 3

Reconocimiento de dígitos manuscritos usando la descomposición en valores singulares

- Datos: base de datos (etiquetada) de imágenes de dígitos manuscritos
- Objetivo: dado una nueva imagen ¿a qué dígito se corresponde?



Pequeño ejemplo


Datos en \mathbb{R}^3

Sea $x^{(1)}, x^{(2)}, \dots, x^{(n)}$ una secuencia de n datos, con $x^{(i)} \in \mathbb{R}^3$

$$X = \begin{pmatrix} 10.898 & 17.477 & 7.4443 \\ 11.018 & 18.777 & 9.1042 \\ 10.157 & 15.845 & 9.6744 \\ 10.065 & 16.378 & 7.8452 \\ 11.072 & 18.227 & 9.0744 \\ \vdots & \vdots & \vdots \\ 28.889 & 38.937 & 22.877 \end{pmatrix}$$

$\uparrow \qquad \qquad \uparrow \qquad \qquad \uparrow$

$x_1 \qquad \qquad x_2 \qquad \qquad x_3$




Pequeño ejemplo

Datos en \mathbb{R}^3

Sea $x^{(1)}, x^{(2)}, \dots, x^{(n)}$ una secuencia de n datos, con $x^{(i)} \in \mathbb{R}^3$

$$X = \begin{pmatrix} x^{(1)t} \\ x^{(2)t} \\ x^{(3)t} \\ x^{(4)t} \\ x^{(5)t} \\ \vdots \\ x^{(n)t} \end{pmatrix}$$




Pequeño ejemplo

Datos en \mathbb{R}^3

Sea $x^{(1)}, x^{(2)}, \dots, x^{(n)}$ una secuencia de n datos, con $x^{(i)} \in \mathbb{R}^3$

$$X = \begin{pmatrix} x_1^{(1)t} & x_2^{(1)t} & x_3^{(1)t} \\ x_1^{(2)t} & x_2^{(2)t} & x_3^{(2)t} \\ \vdots & \vdots & \vdots \\ x_1^{(n)t} & x_2^{(n)t} & x_3^{(n)t} \end{pmatrix}$$



Pequeño ejemplo

Datos en \mathbb{R}^3

Sea $x^{(1)}, x^{(2)}, \dots, x^{(n)}$ una secuencia de n datos, con $x^{(i)} \in \mathbb{R}^3$

$$X = \begin{pmatrix} 10.898 & 17.477 & 7.4443 \\ 11.018 & 18.777 & 9.1042 \\ 10.157 & 15.845 & 9.6744 \\ 10.065 & 16.378 & 7.8452 \\ 11.072 & 18.227 & 9.0744 \\ \vdots & \vdots & \vdots \\ 28.889 & 38.937 & 22.877 \end{pmatrix}$$

$\uparrow \qquad \qquad \uparrow \qquad \qquad \uparrow$


$x_1 \qquad \qquad x_2 \qquad \qquad x_3$

$$\bar{x}_1 = 19.96, \bar{x}_2 = 27.902, \bar{x}_3 = 15.581$$


$$\sigma_{x_1} = 35.26, \sigma_{x_2} = 5.93, \sigma_{x_3} = 4.13$$

Varianza de una variable x_k :


$$\sigma_{x_k} = \frac{1}{n-1} \sum_{i=1}^n (x_k^{(i)} - \bar{x}_k)^2$$



Varianza



$$\sigma = 9.49$$




$$\sigma = 1.52$$

Varianza de n observaciones de una variable


$$\sigma_{X_1} = \frac{1}{n-1} \sum_{i=1}^n (x_1^{(i)} - \bar{x}_1)^2$$

Covarianza



$$\sigma_{W,Z} = 93.07$$

$$\sigma_{W,Z} = \frac{1}{n-1} \sum_{i=1}^n (w^{(i)} - \bar{w})(z^{(i)} - \bar{z})$$



$$\sigma_{W,Z} = 847.71$$

Variables con mayor covarianza inducen presencia de cierta de dependencia o relación

Covarianza entre variables

Dadas de n observaciones de dos variables x_k y x_j :

$$\sigma_{x_k, x_j} = \frac{1}{n-1} \sum_{i=1}^n (x_k^{(i)} - \bar{x}_k)(x_j^{(i)} - \bar{x}_j) = \frac{1}{n-1} (x_k - \bar{x}_k)^t (x_j - \bar{x}_j)$$

Matriz de Covarianza

Sea $x^{(1)}, x^{(2)}, \dots, x^{(n)}$ una secuencia de n datos, con $x^{(i)} \in \mathbb{R}^3$

$$X = \begin{pmatrix} 10.898 - \bar{x}_1 & 17.477 - \bar{x}_2 & 7.4443 - \bar{x}_3 \\ 11.018 - \bar{x}_1 & 18.777 - \bar{x}_2 & 9.1042 - \bar{x}_3 \\ 10.157 - \bar{x}_1 & 15.845 - \bar{x}_2 & 9.6744 - \bar{x}_3 \\ 10.065 - \bar{x}_1 & 16.378 - \bar{x}_2 & 7.8452 - \bar{x}_3 \\ 11.072 - \bar{x}_1 & 18.227 - \bar{x}_2 & 9.0744 - \bar{x}_3 \\ \vdots & \vdots & \vdots \\ 28.889 - \bar{x}_1 & 38.937 - \bar{x}_2 & 22.877 - \bar{x}_3 \end{pmatrix}$$

$\uparrow \qquad \qquad \uparrow \qquad \qquad \uparrow$

$x_1 \qquad \qquad x_2 \qquad \qquad x_3$

$$M_X = \begin{pmatrix} \sigma_{x_1, x_1} & \sigma_{x_1, x_2} & \sigma_{x_1, x_3} \\ \sigma_{x_2, x_1} & \sigma_{x_2, x_2} & \sigma_{x_2, x_3} \\ \sigma_{x_3, x_1} & \sigma_{x_3, x_2} & \sigma_{x_3, x_3} \end{pmatrix}$$

$$M_X = \frac{1}{n-1} X^t X$$

¿Cómo expresar *mejor* nuestros datos?

Cambio de base: $\hat{X}^t = PX^t$

- ▶ Disminuir la redundancia en los datos (\downarrow covarianza)

Cómo?

- ▶ Diagonalizar la matriz de covarianza

¿Cómo expresar *mejor* nuestros datos?

Cambio de base: $\hat{X}^t = PX^t$

- ▶ Disminuir la redundancia en los datos (\downarrow covarianza)

Cómo?

- ▶ Diagonalizar la matriz de covarianza

¿Cómo expresar *mejor* nuestros datos?

Cambio de base: $\hat{X}^t = P X^t$

Sea P ortogonal y $M_{\hat{X}}$ la matriz de covarianza de \hat{X}

$$\begin{aligned} M_{\hat{X}} &= \frac{1}{n-1} \hat{X}^t \hat{X} \\ &= \frac{1}{n-1} (P X^t) (X P^t) \\ &= P \frac{X^t X}{n-1} P^t \\ M_{\hat{X}} &= P M_X P^t \end{aligned}$$

Toda matriz simétrica es diagonalizable

Teorema

Si $B \in \mathbb{R}^{n \times n}$ es simétrica entonces existe una base ortonormal de autovectores $\{v_1, \dots, v_n\}$ asociados a autovalores $\lambda_1, \dots, \lambda_n$

$$\begin{aligned} \text{Entonces: } B \left(v_1 \mid \dots \mid v_n \right) &= \left(Bv_1 \mid \dots \mid Bv_n \right) = \\ \left(\lambda_1 v_1 \mid \dots \mid \lambda_n v_n \right) &= \left(v_1 \mid \dots \mid v_n \right) \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix} \\ \implies B &= \left(v_1 \mid \dots \mid v_n \right) \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix} \left(v_1 \mid \dots \mid v_n \right)^t \end{aligned}$$

¿Cómo expresar *mejor* nuestros datos?

Cambio de base: $\hat{X}^t = P X^t \implies M_{\hat{X}} = P M_X P^t$

M_X es simétrica \implies tiene una base ortonormal de autovectores \implies es diagonalizable $\implies M_X = V D V^t$

$$\begin{aligned} M_{\hat{X}} &= P M_X P^t \\ &= P (V D V^t) P^t && \text{elijo } P := V^t \\ &= V^t (V D V^t) V \\ &= (V^t V) D (V^t V) \\ &= D \end{aligned}$$

Con esta elección de P se diagonaliza la matriz de covarianzas de los datos transformados.

Matriz de Covarianza


Sea $x^{(1)}, x^{(2)}, \dots, x^{(n)}$ una secuencia de n datos, con $x^{(i)} \in \mathbb{R}^3$

$$X = \begin{pmatrix} 10.898 - \bar{x}_1 & 17.477 - \bar{x}_2 & 7.4443 - \bar{x}_3 \\ 11.018 - \bar{x}_1 & 18.777 - \bar{x}_2 & 9.1042 - \bar{x}_3 \\ 10.157 - \bar{x}_1 & 15.845 - \bar{x}_2 & 9.6744 - \bar{x}_3 \\ 10.065 - \bar{x}_1 & 16.378 - \bar{x}_2 & 7.8452 - \bar{x}_3 \\ 11.072 - \bar{x}_1 & 18.227 - \bar{x}_2 & 9.0744 - \bar{x}_3 \\ \vdots & \vdots & \vdots \\ 28.889 - \bar{x}_1 & 38.937 - \bar{x}_2 & 22.877 - \bar{x}_3 \end{pmatrix}$$

$\uparrow \qquad \qquad \uparrow \qquad \qquad \uparrow$
 $x_1 \qquad \qquad x_2 \qquad \qquad x_3$

$$M_X = \begin{pmatrix} 35 & 34.27 & 23.67 \\ 34.274 & 35.26 & 23.80 \\ 23.675 & 23.80 & 17.43 \end{pmatrix}$$

$$M_X = \frac{1}{n-1} X^t X$$





Diagonalización Matriz de Covarianza

$$\begin{aligned} M_X &= \begin{pmatrix} 35 & 34.27 & 23.67 \\ 34.27 & 35.26 & 23.80 \\ 23.67 & 23.80 & 17.43 \end{pmatrix} = \\ &= \underbrace{\begin{pmatrix} 0.62 & 0.46 & 0.63 \\ -0.75 & 0.14 & 0.63 \\ 0.20 & -0.87 & 0.44 \end{pmatrix}}_V \underbrace{\begin{pmatrix} 0.85 & 0 & 0 \\ 0 & 0.97 & 0 \\ 0 & 0 & 85.8 \end{pmatrix}}_D \underbrace{\begin{pmatrix} 0.62 & -0.75 & 0.20 \\ 0.46 & 0.14 & -0.87 \\ 0.63 & 0.63 & 0.44 \end{pmatrix}}_{V^t} \end{aligned}$$

Transformación de los datos

Cambio de base ($P = V^t$): $\hat{X}^t = V^t X^t$




$$M_X = \begin{pmatrix} 35 & 34.27 & 23.67 \\ 34.27 & 35.26 & 23.80 \\ 23.67 & 23.80 & 17.43 \end{pmatrix}$$

$$M_{\hat{X}} = \begin{pmatrix} 85.8 & 0 & 0 \\ 0 & 0.97 & 0 \\ 0 & 0 & 0.85 \end{pmatrix}$$

Propiedades del cambio de base

- ▶ disminuye redundancias
- ▶ minimiza el error
- ▶ captura la dinámica de interés de los datos (si se ordena autovalores según módulo)



Usando la descomposición en valores singulares

Consideremos la matriz de datos $A \in \mathbb{R}^{n \times m}$

- ▶ n muestras y m variables
- ▶ Supongamos que las muestras en A tienen media 0
- ▶ Definimos a $X = A/\sqrt{n-1}$
- ▶ Sea $X = U\Sigma V^t$ la descomposición SVD de X
- ▶ V es ortogonal con autovectores de $X^tX = (A^tA)/(n-1)$

Los columnas de V contienen los autovectores
de la matriz de covarianza

Reconociendo dígitos

Base de datos MNIST

- ▶ 6000 dígitos
- ▶ Cada dígito es una imagen de 28×28 píxeles



8 7 1 4 2 4 9 0 4 3 9 4 2 4 6 3 5 4 7 1 8 0 7 6 7 2 0 4 4 4 3 8
6 9 0 6 0 2 7 7 6 7 2 0 2 8 8 8 8 1 7 2 7 5 2 1 1 3 0 2 4 0 5 9
9 3 0 8 0 8 0 4 5 5 1 4 9 9 4 1 9 2 8 6 0 5 4 8 2 7 0 8 5 9 8 6
4 9 1 0 2 5 9 9 2 8 1 8 0 1 7 6 5 8 1 3 9 8 2 9 5 3 3 3 1 0 6 7
0 8 7 7 0 8 2 7 6 0 4 0 3 9 7 5 6 7 9 5 7 3 8 0 9 2 1 2 6 4 5 8
9 5 1 8 2 6 9 8 4 9 4 4 9 2 4 1 7 1 2 7 7 6 1 6 5 4 6 4 5 1 9 4
1 9 6 3 7 9 5 3 7 1 5 3 6 8 4 1 9 2 0 6 5 2 1 6 6 1 2 1 7 5 7 7
1 3 3 1 1 3 1 2 1 0 6 6 7 7 9 0 9 6 5 8 0 3 3 7 7 6 2 5 7 4 2 5

Reconociendo dígitos

Ejemplo con base de sólo imágenes de los dígitos 0, 5 y 8.



Reconociendo dígitos

Ejemplo con dígitos 0, 5 y 8.

- ▶ La base MNIST tiene 17195 imágenes de estos 3 dígitos
- ▶ $28 \times 28 = 784$ píxeles por imagen (cada pixel, una variable)
- ▶ Sea $x^{(1)}, x^{(2)}, \dots, x^{(17195)}$ cada una de las imágenes dispuestas en un vector en \mathbb{R}^{784}
- ▶ Sea $\mu = \left(\sum_{i=1}^{17195} x^{(i)} \right) / 17195$ la imagen promedio.
- ▶ Definimos X como una matriz en $\mathbb{R}^{17195 \times 784}$
- ▶ El vector $\frac{(x^{(i)} - \mu)^t}{\sqrt{783-1}}$ en la fila i -ésima de X

Reconociendo dígitos


Ejemplo con dígitos 0, 5 y 8.

- ▶ Calculamos $X = U\Sigma V^t$ la descomposición SVD de X
- ▶ Las columnas de V tienen los autovectores de la matriz de covarianza $X^t X$
- ▶ Transformamos cada imagen: $\hat{x}^{(i)} = V^t x^{(i)}$

Reconociendo dígitos

Ejemplo con dígitos 0, 5 y 8.


- Graficamos en \mathbb{R}^3 las primeras 3 componentes de cada $\hat{x}^{(i)}$




Reconociendo dígitos

Reconstrucción con menos componentes


digito 0 \in base




$K = 5$



$K = 10$



$K = 30$



$K = 60$



Reconociendo dígitos

Reconstrucción con menos componentes

digito 8 \in base



$K = 5$



$K = 10$



$K = 30$



$K = 60$




Reconociendo dígitos

Reconstrucción con menos componentes


digito 5 \in base



$K = 5$



$K = 10$



$K = 30$




$K = 60$




Reconociendo dígitos

'AUTODIGITOS' (autovectores de la matriz de covarianza)



Reconociendo dígitos

Varianzas (plot de la diagonal de la matriz Σ)



Cálculo de autovectores/autovalores

Métodos a utilizar

- ▶ Algoritmo QR
- ▶ Método de la potencia + deflación

Cálculo de autovectores/autovalores

Algoritmo QR

repeat

 Factorizar $A_k = Q_k R_k$;

$A_{k+1} \leftarrow R_k Q_k$;

until A_{k+1} sea triangular inferior ;

- Notar que A_{k+1} y A_k son matrices semejantes:

$$\begin{aligned} A_{k+1} &= R_k Q_k \\ &= Q_k^t Q_k R_k Q_k \\ &= Q_k^{-1} A_k Q_k \end{aligned}$$

Cálculo de autovectores/autovalores

Algoritmo QR

- ▶ Luego de varias iteraciones

$A_0 \rightsquigarrow A_1 \rightsquigarrow A_2 \rightsquigarrow \cdots \rightsquigarrow A_k \longrightarrow$ matriz triangular inferior

- ▶ Si la matriz inicial es simétrica, el algoritmo QR tiende a una matriz diagonal
- ▶ Comenzando con $A_0 = A$

$$\begin{aligned} A_{k+1} &= R_k Q_k \\ &= Q_k^{-1} A_k Q_k \\ &= Q_k^{-1} Q_{k-1}^{-1} A_{k-1} Q_{k-1} Q_k \\ &= \underbrace{Q_k^{-1} Q_{k-1}^{-1} \cdots Q_0^{-1}}_{V^{-1}} A_0 \underbrace{Q_0 \cdots Q_{k-1} Q_k}_V \end{aligned}$$

- ▶ Obtenemos autovectores en V : $A = V A_{k+1} V^{-1}$

Cálculo de autovectores/autovalores

Algoritmo QR - Condición de parada

- ▶ Sea $A^{(k)} = (a_{ij}^{(k)})$ la matriz de $m \times m$ obtenida en la k -ésima iteración
- ▶ $A^{(k)}$ simétrica tiende a una matriz diagonal
- ▶ Definimos como condición de corte:

$$\sum_{i=2}^m \sum_{j=1}^{i-1} |a_{ij}^{(k)}| < \delta$$

donde $\delta \in \mathbb{R}_+$ es un parámetro de la implementación

- ▶ Es decir, el método se interrumpe si la suma de los módulos de los elementos de la parte triangular inferior de $A^{(k)}$ sea inferior a δ

Cálculo de autovectores/autovalores

Método de la potencia + deflación

```
for  $i = 1$  to  $k$  do  
     $v_i \leftarrow \text{MetodoPotencia}(A)$  ;  
     $\lambda_i \leftarrow (v_i^t A v_i) / (v_i^t v_i)$  ;  
     $A \leftarrow A - \lambda_i v_i v_i^t$  ; // deflación  
end
```

Propiedad: Sea $A \in \mathbb{R}^{n \times n}$ una matriz con autovalores distintos $\lambda_1 > \lambda_2 > \dots > \lambda_n$ y una base ortonormal de autovectores.

- La matriz $A - \lambda_1 v_1 v_1^t$ tiene autovalores $0, \lambda_2, \dots, \lambda_n$, con autovectores asociados v_1, \dots, v_n

Este método solo funciona si tengo autovalores todos distintos